LOGO

BigData Engineering

13주차: Data Engineering
Workflow Example
(Kaggle –Titanic Dataset)

강의 : 신경섭

We covered…

- Data management/Visualization by python
  - Numpy, pandas, data acquisition
- Machine learning workflow with data
- EDA (Exploratory Data Analysis)
- Supervised learning
  - k-NN classifier
  - logistic regression based binary classification
  - Support vector machine
  - Decision tree
  - Random Forest
- Model Evaluation

Course Evaluation

- Attendance : 10%
- Homework : 40%
- Final Project : 50%
  - 다양한 데이터셋을 시각화하여 분석하는 프로젝트
  - 평가방법 : 데이터의 시각화, 데이터의 분석 등
  - Copy는 지양하고 창의적으로 만들어보시기 바랍니다.
  - Jupyter notebook file, readme file, pdf file, dataset file 네가지 압축하여 제출 (파일명: 학번_이름.zip)
    - Readme 파일: 데이터출처, 추가 패키지 설치 필요한 경우 설명 작성
    - pdf 파일: jupyter notebook 단순 변환
  - 데이터셋 참조
    - https://brunch.co.kr/@data/10
    - https://brunch.co.kr/@jowlee/118

Represent / Train / Evaluate / Refine Cycle

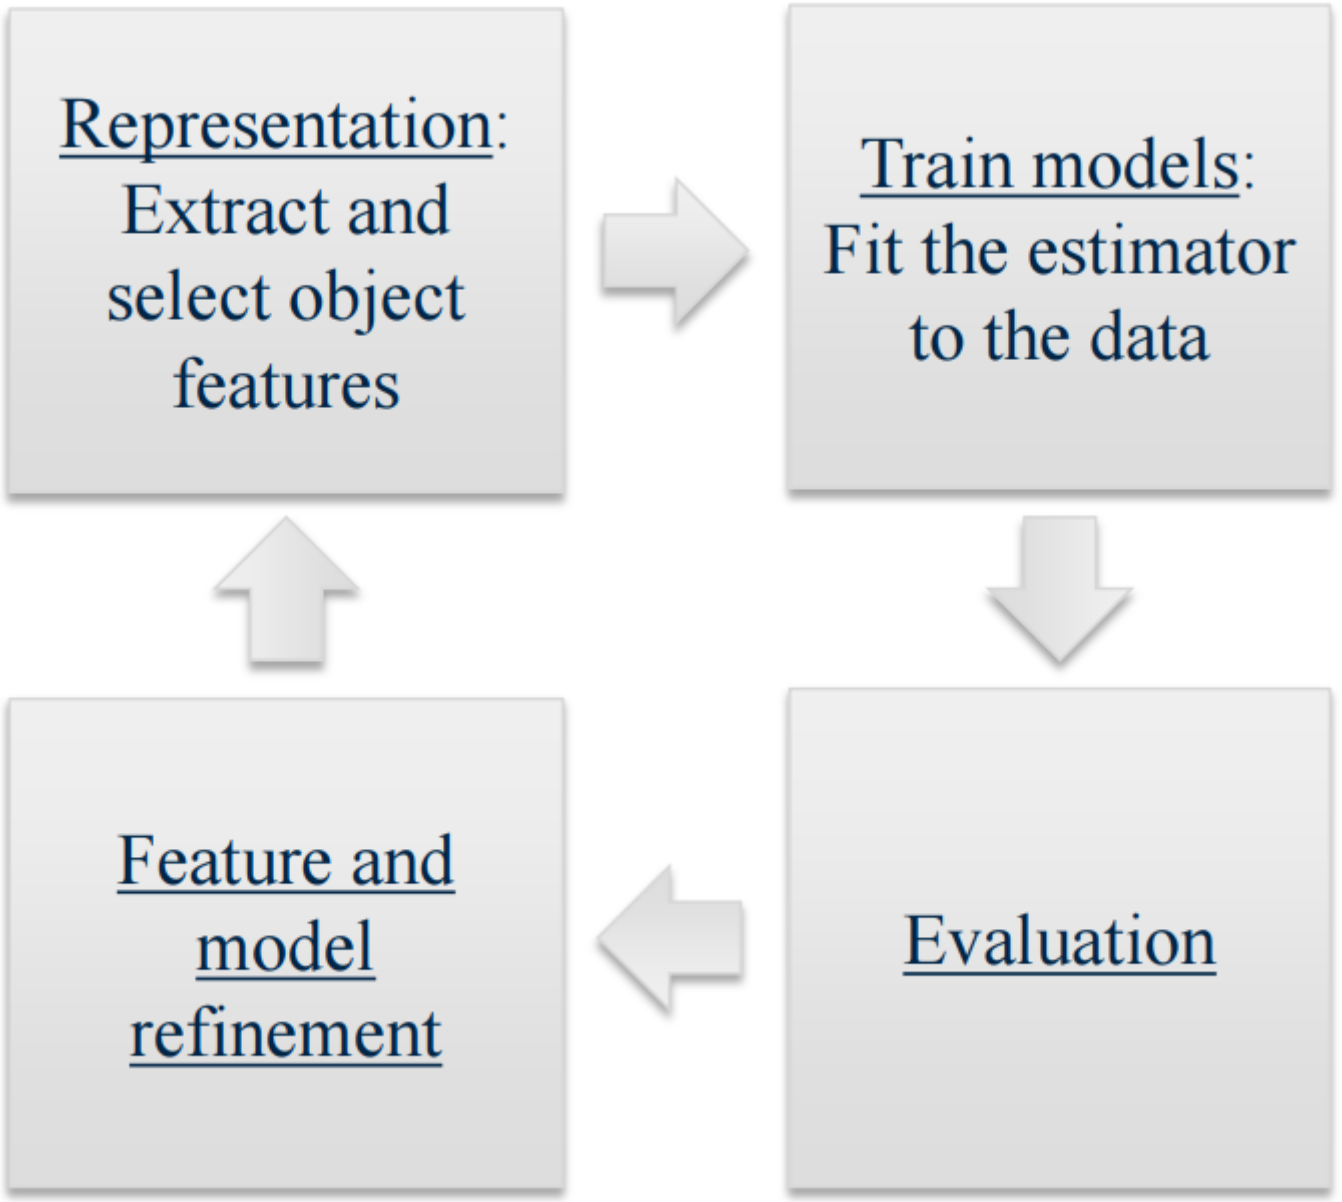

Sci-kit Learn Library reference

- https://www.datacamp.com/community/blog/scikit-learn-cheat-sheet

Kaggle competition

- https://www.kaggle.com/c/titanic/overview

- Material
  - https://www.kaggle.com/ash316/eda-to-prediction-dietanic